

Projet Analyse de survie

Introduction

L'analyse de survie est un ensemble de méthodes qui étudient le temps écoulé avant la survenue d'un événement donné (décès d'un patient, panne d'une machine, guérison d'un patient, rupture de contrat, etc.), en tenant compte du fait que pour certains individus on ne connaîtra pas l'instant exact de la survenue de l'événement (données « censurées »).

L'analyse de survie est basée sur des données collectées par exemple sous forme d'enquête auprès des patients atteints d'une pathologie (décès) ou dans une usine sur des machines utilisées dans la production (panne). Les données de survie mesurent donc la durée jusqu'à la survenue d'un événement important comme le décès ou la panne d'un système. On observe un temps de suivi entre un point de départ (diagnostic, mise en service d'un appareil, embauche, etc.) et un événement (décès, panne, départ, etc.).

Contexte : Analyse de survie de patients.

Documents :

Librairie Python : lifelines

Cette librairie est complète et vous allez vous baser sur son contenu pour faire les différentes analyses. Le lien ci-dessous décrit les méthodes et donne le code Python pour chaque méthode.

<https://lifelines.readthedocs.io/en/latest/Survival%20Analysis%20intro.html>

Suivre des vidéos d'introduction à l'analyse de survie. Voici quelques liens mais vous pouvez en trouver beaucoup d'autres vidéos.

https://youtu.be/t6vdjwhauF8?si=-_jmKCzXs3nWlfj4

<https://youtu.be/dYorCZaF8ag?si=6ae8xaxYzVMPNUd9>

Fichier de données :

Le fichier de données `survival_data_1000.csv` contient des informations sur des patients avec les variables clés comme l'âge, le sexe, le statut de fumeur, les comorbidités, le traitement, l'activité physique et l'IMC. L'objectif est d'exploiter ces données pour faire une analyse de survie des patients et d'identifier plusieurs facteurs influençant significativement la durée de survie.

Les variables utilisées sont : l'âge, le sexe, le statut de fumeur (O/N), la présence de comorbidités, le traitement, l'indice de masse corporelle, l'activité physique, le temps jusqu'à la survenue de l'évènement, et le décès (O/N).

Travail à faire

1. Dans la mesure du possible et si les conditions le permettent, faire une enquête auprès de certains patients ayant une même pathologie. Le questionnaire est à construire pour répondre aux besoins d'analyse ci-dessous. Dans l'idéal, le projet aurait eu plus de sens si on fait une enquête quantitative auprès d'un échantillon représentatif de patients de patient atteints d'une pathologie donnée aura été souhaitée et collecter les données à analyser. A défaut, on utilise les données `survival_data_1000.csv`
2. Etudier les fonctionnalités de la librairie « lifelines » qui permettent de faire de l'analyse de survie. Dresser la liste des principales fonctions avec un bref descriptif de ces fonctions
3. Fournir une interface (Web) permettant d'afficher les résultats de l'analyse selon les recommandations ci-dessous. **L'application Web** est créée en utilisant la librairie python **streamlit** (voir plus de détails ci-dessous).

Lecture des données :

- Proposer la lecture du fichier de données csv en utilisant une boîte de dialogue et choix du fichier
- Proposer la possibilité de choisir le format des données CSV (formats : UTF8, Latin,...).
- Utiliser le fichier CSV « `survival_data_1000.csv` » pour faire les tests des différentes fonctions.
- Sélectionner la variable « `Time_to_Event` » et la variable « `Event_Observed` ».
- A partir de la variable `Age`, créer une nouvelle variable `Tranche_Age` (<50, 50-60, >60)
- A partir de la variable `BMI`, créer une nouvelle variable `Tranche_BMI` (<18, 18-26, >26)
- Vérifier dans le fichier de données qu'un patient n'est présent qu'une fois dans le fichier. Supprimer les lignes en doublons pour les patients avec un « `Event_Observed=0` ».

Fonctionnalités de l'application

Gestion des données manquantes.

Remplacer les données manquantes selon le cas (suppression de ligne, de colonne, remplacement par une valeur moyenne ou médiane, ...).

Analyse de Survie avec la méthode de Kaplan-Meier

Le premier objectif de ce travail est d'utiliser Python pour **l'analyse de survie** afin d'estimer la probabilité de survie des patients et visualiser les courbes de survie en fonction de différentes variables.

1. **Estimer la probabilité de survie et l'intervalle de confiance** en utilisant la méthode de Kaplan-Meier.
2. **Afficher le tableau des proportions de survivants** à chaque instant t ($t = 0, \dots, n$).
3. **Tracer la courbe de survie globale avec son intervalle de confiance.**
4. **Comparer la survie en fonction d'un critère (par exemple le sexe H/F)** en traçant les courbes Kaplan-Meier pour chaque groupe.

Estimation de la fonction de risque (Hazard rate)

- Utiliser la classe NelsonAalenFitter de lifelines pour estimer la **cumulative hazard function**.
- Tracer la **courbe du risque cumulé**.
- Expliquer l'évolution du risque en fonction du temps.
- Proposer une estimation de la survie lorsqu'on saisit une valeur de temps saisie (mois ou année) dans une case de saisie.

Répondre aux questions suivantes :

- a) Que représente la **fonction de risque cumulée** estimée par la méthode de **Nelson-Aalen** ?
- b) Comment évolue le risque cumulatif avec le temps ? Que peut-on en déduire sur la maladie étudiée ?

Régression de survie avec le Modèle de Cox

L'objectif est d'estimer l'impact des variables explicatives suivantes sur la survie des patients : Sex, Âge, Smoker, Treatment et T Physical_Activity;

- Ajuster un modèle de Cox en utilisant ces variables comme covariables.
- Interpréter les coefficients estimés (Hazard Ratios).
- Vérifier les hypothèses du modèle de Cox, notamment l'hypothèse de proportionnalité des risques.
- Visualiser les courbes de survie ajustées selon certaines variables clés.

Tests de comparaison des fonctions de survie

Faire le test de comparaison de Mantel-Haenszel (log-rank) pour comparer deux ou plusieurs groupes (par exemple par genre ou par CSP)

Présentation de la page Web

L'application Web est à réaliser avec la librairie **streamlit** de Python. Cette librairie permet de créer très facilement des applications web interactives pour visualiser des résultats, des graphiques pour la data science, le machine learning.

Une barre latérale contenant les fonctionnalités de sélection des variables et des sous-groupes d'individus.

Une barre horizontale (en haut de la page) contenant les onglets des analyses à faire :

- Visualisation des données
- Traitement des données manquantes
- Statistiques descriptives
- Représentations graphiques des variables
- Probabilités de survie et courbes de survie
- Prédiction de survie d'un individu
- Modèle de régression de Cox

Remarques

Une autre librairie peut être utilisée : « plotly » couplée à la librairie « Dash ».

Vous pouvez explorer et utiliser d'autres librairies utiles pour le projet.

Variables à utiliser en tant que filtres :

Sur la barre latérale, on peut filtrer les données sur quelques variables parmi les variables suivantes : Age ; Sex ; Smoker ; Comorbidities ; Treatment ; BMI ; Physical_Activity

Librairie streamlit

Voici deux exemples de tutoriels introduisant l'utilisation de streamlit. De nombreux tutoriels existent sur le net.

https://youtu.be/7pbhs1jLhRA?si=YzI9bOO7_OC_4Az5

https://www.youtube.com/live/REQzcp0q1FU?si=K4CSGb_yicsiHXY5

Livrables

1 – Rapport pdf décrivant le travail réalisé

- Les librairies utilisées (guide explicatif des librairies utilisées et pour quelle tâches)
- Descriptif et documentation de l'application (onglets, les fonctions créées éventuellement, ...)
- Application Web hébergée et accessible en ligne.
- Descriptif du mode de déploiement de l'application sur un serveur Web.
- Qu'est ce qui ne fonctionne pas.

- Difficultés rencontrées
- Pistes d'amélioration

2 – Code source commenté avec le fichier des données utilisé.

4 – prévoir une présentation orale suivie de questions